

Tarification du risque automobile

Comparaison entre modélisation GLM et méthodes de machine learning



DIOUF Salimata
KOUAME Christ Ange Dylan
OUATTARA Aboubakar Mohamed
OUATTARA Souleymane

Avril 2026



Enseignante : Esterina MASIELLO

Table des matières

1	Tarification par Modèles Linéaires Généralisés (GLM)	3
1.1	Résumé	3
1.2	Analyse descriptive	4
1.2.1	Présentation des données	4
1.2.2	Distribution de la sinistralité	4
1.2.2.1	Nombre de sinistres et fréquence globale	4
1.2.2.2	Montant des sinistres	5
1.2.3	Analyse univariée par facteur de risque	5
1.2.4	Analyse de corrélation et de liaison	7
1.2.4.1	Corrélations quantitatives (Pearson)	7
1.2.4.2	Mesure η^2 (liaison variable $\rightarrow$ sévérité)	7
1.3	Construction de la base de données : fréquence et sévérité	8
1.3.1	Fusion des tables	8
1.3.2	Nettoyage complet des données	8
1.3.3	Séparation sinistres attritionnels / atypiques (CAT)	9
1.3.3.1	choixmethodo	10
1.3.4	Surprime CAT	10
1.3.5	Recodage des variables	11
1.3.6	Modalités de référence	11
1.3.7	Partitionnement apprentissage / test	11
1.4	Modélisation par GLM	12
1.4.1	Modélisation de la fréquence	12
1.4.1.1	Cadre théorique	12
1.4.1.2	Modèle nul (pois0) et Poisson complet (pois1)	12
1.4.1.3	Sélection backward stepAIC (pois4 $\rightarrow$ pois5)	12
1.4.1.4	Test de surdispersion et modèle Binomiale Négative (nbinom1)	12
1.4.1.5	Modèles à inflation de zéros (ZIP, ZINB, Hurdle)	13
1.4.1.6	Comparaison globale des modèles de fréquence	13
1.4.2	Modélisation de la sévérité	14
1.4.2.1	Cadre théorique	14
1.4.2.2	Modèle Gamma — Sélection de variables (gamma4)	14
1.4.2.3	Modèle Log-normale — Sélection de variables (gauss2)	15
1.4.2.4	Gaussienne Inverse (igauss4)	15
1.4.2.5	Comparaison des modèles de sévérité	15
1.5	Analyse des résultats	16
1.5.1	Calcul de la prime pure	16
1.5.2	Synthèse des choix méthodologiques	17
1.5.3	Synthèse comparative des modèles retenus	17
1.6	Limites et perspectives	17
1.6.1	Limites de l'approche GLM	17

1.6.2	Perspectives	18
2	Tarification par Machine Learning	19
2.1	Estimation de la fréquence	19
2.1.1	Résumé	19
2.1.2	Gestion du déséquilibre des classes	19
2.1.2.1	Problématique	19
2.1.2.2	Utilisation de méthodes de rééchantillonnage préférentiel	20
2.1.3	Méthodes de machine learning combinées au rééchantillonnage	20
2.2	Estimation du coût	21
2.2.1	Résumé	21
2.2.2	Analyse des sinistres attritionnels	22
2.2.2.1	Objectif et logique de modélisation	22
2.2.2.2	Critères de comparaison et sélection du modèle	22
2.2.2.3	Résultats et interprétation pratique	23
2.2.3	Traitement des sinistres atypiques	24
2.2.3.1	Volumétrie et justification d'un traitement séparé	24
2.2.3.2	Étape EVT / GPD	24
2.2.3.3	Modélisation machine learning des atypiques	24
2.2.3.4	Modèle retenu et logique hybride	24
2.2.3.5	Implication pratique	25
2.2.4	Prédiction de la probabilité d'avoir un sinistre attritionnel ou atypique	26
2.2.4.1	Idée et utilité pratique	26
2.2.4.2	Méthodologie et modèles testés	26
2.2.4.3	Modèle retenu	26
2.2.5	Prédiction du coût total	27
2.2.5.1	Principe général	27
2.2.5.2	Pondération et logique de combinaison	27
3	Synthèse	29
3.1	Analyse et comparaison des résultats avec la méthode GLM	29
3.1.1	Prédiction de la fréquence	29
3.1.2	Prédiction du coût	30
3.1.2.1	Résultats obtenus et interprétation	30
3.1.2.2	Assuré de référence	32
3.1.2.3	Recommandation pratique	33
3.2	Tableau comparatif GLM VS ML	33
3.3	Limites et perspectives	34
3.3.1	Limites pratiques et concurrentielles des approches retenues	34
3.3.2	Approche à privilégier en pratique	34
3.3.3	Ce qu'il faudrait pour aller vers des méthodes plus poussées	35
	Conclusion	36
	Références bibliographiques	37

Chapitre 1

Tarification par Modèles Linéaires Généralisés (GLM)

1.1 Résumé

Ce rapport présente une étude complète de tarification en assurance Responsabilité Civile (RC) automobile, réalisée à partir des données **freMTPLfreq** et **freMTPLsev** du package R **CASdatasets**. Ces deux tables décrivent un portefeuille de polices françaises : caractéristiques contractuelles d'un côté, montants individuels de sinistres de l'autre.

L'objectif est de calculer une **prime pure individuelle** pour chaque profil de risque, selon la décomposition actuarielle classique fréquence $\times$ sévérité :

$$\hat{\Pi}_i = \underbrace{\hat{\lambda}_i}_{\text{fréquence}} \times \underbrace{\hat{s}_i}_{\text{sévérité attritionnelle}} + \underbrace{\hat{\pi}^{\text{CAT}}}_{\text{surprime atypiques}}$$

La démarche comporte cinq étapes : construction et nettoyage approfondi des bases (six filtres), analyse descriptive incluant une mesure η^2 , modélisation de la fréquence (GLM Poisson, Binomiale Négative, modèles à inflation de zéros et hurdle), modélisation de la sévérité (Gamma, Gaussienne Inverse, Log-normale), puis calcul et interprétation de la prime pure.

Résultat clé

Indicateur	Valeur
Taille du portefeuille brut (freMTPLfreq)	413 169 polices
Taille du portefeuille (après nettoyage)	402 639 polices
Seuil sinistres atypiques ($Q_{97,5\%}$)	7 491 EUR
Part sinistres atypiques dans le coût total	44,15 %
Surprime CAT forfaitaire	37,02 EUR/police/an
Fréquence annuelle globale	0,0705 sinistre/an
Sévérité attritionnelle moyenne (base app.)	1 222,6 EUR
Modèle fréquence retenu	Binomiale Négative
Modèle sévérité retenu	Gamma
Prime pure profil de référence	207,13 EUR/an

1.2 Analyse descriptive

1.2.1 Présentation des données

TABLE 1.1 – Description des tables brutes (package `CASdatasets`)

Table	Contenu	Lignes	Colonnes
<code>freMTPLfreq</code>	Caractéristiques des polices + nb sinistres	413 169	10
<code>freMTPLsev</code>	Montant individuel de chaque sinistre	16 181	2

La vérification de cohérence confirme que la somme de `ClaimNb` dans `freMTPLfreq` (= 16 181) correspond exactement au nombre de lignes de `freMTPLsev`, ce qui valide la fusion des deux tables par `PolicyID`.

TABLE 1.2 – Description des variables explicatives

Variable	Type	Description
<code>Exposure</code>	Continue	Fraction d'année couverte $\in (0, 2]$, médiane = 0,54
<code>Power</code>	Catégorielle	Puissance du véhicule (12 modalités : d à o)
<code>CarAge</code>	Entier ≥ 0	Âge du véhicule ; médiane = 7 ans, max = 100
<code>DriverAge</code>	Entier ≥ 0	Âge du conducteur ; médiane = 44 ans, min = 18
<code>Brand</code>	Catégorielle	Marque du véhicule (7 modalités)
<code>Gas</code>	Binaire	Carburant : Diesel (205 945) / Regular (207 224)
<code>Region</code>	Catégorielle	Région de résidence (10 modalités)
<code>Density</code>	Entier	Densité de population (hab/km ²), médiane = 287, max = 27 000
<code>ClaimNb</code>	Entier ≥ 0	Nombre de sinistres dans la période (max = 4)

1.2.2 Distribution de la sinistralité

1.2.2.1 Nombre de sinistres et fréquence globale

Après application de l'ensemble des filtres de nettoyage (section 1.3), le portefeuille final contient **402 639 polices** (387 585 non sinistrées, soit 96,26 %, et 15 054 sinistrées, soit 3,74 %). La proportion de polices non sinistrées dépasse 96 %, trait structurel des portefeuilles RC automobile qui justifie d'examiner des modèles à inflation de zéros en complément du GLM Poisson standard.

La fréquence annuelle globale est :

$$\hat{\lambda}_{\text{global}} = \frac{\sum_i N_i}{\sum_i E_i} \approx 0,070 \text{ sinistre/an}$$

1.2.2.2 Montant des sinistres

TABLE 1.3 – Statistiques descriptives des coûts de sinistres (base brute)

Base	Obs.	Min	Médiane	Moyenne	Max
Tous sinistres (<code>basecout</code>)	15 819	2	1 120	2 134	2 036 833
Attritionnels (<code>basecoutattri</code>)	15 423	2	≈940	1 222,6	7 490,75
Atypiques (<code>basecoutatyp</code>)	396	>7 490	19 305	37 631	2 036 833

Remarque

Le seuil $Q_{97,5\%} = 7\,490,75$ EUR (section 1.3) sépare les 15 423 sinistres attritionnels (sévérité moyenne : 1 222,6 EUR) des 396 sinistres atypiques (sévérité moyenne : ≈ 37 644 EUR). Les atypiques représentent seulement 2,5 % des sinistres mais concentrent 44,15 % du coût total — illustration de la loi de Pareto en RC automobile.

1.2.3 Analyse univariée par facteur de risque

Pour chaque variable v , on calcule la fréquence annuelle empirique par modalité k :

$$\hat{\lambda}_k = \frac{\sum_{i \in G_k} N_i}{\sum_{i \in G_k} E_i}$$

et on représente graphiquement l'exposition (barres) et la fréquence avec intervalles de confiance à 95 % (courbe rouge avec $\pm 1,96 \hat{\sigma} / \sqrt{n}$) via la fonction `graphSinistre`.

Âge du conducteur (`DriverAge`) La fréquence décroît fortement avec l'âge, avec une sur-sinistralité très marquée pour les jeunes conducteurs. La borne inférieure est fixée à 16 ans (âge légal) et la borne supérieure à 80 ans après nettoyage (section 1.3) :

TABLE 1.4 – Fréquence annuelle par tranche d'âge du conducteur (analyse exploratoire)

Tranche	Fréquence annuelle
[16, 25[	0,1550
[25, 30[	0,0855
[30, 35[	0,0675
[35, 40[	0,0639
[40, 45[	0,0691
[45, 50[	0,0739
[50, 55[	0,0698
[55, 60[	0,0603
[60, 65[	0,0601
[65, 70[	0,0545
[70, 80]	0,0577

Les 16–25 ans ont une fréquence **plus de deux fois** supérieure à la tranche 35–45 ans, qui constitue la référence de modélisation. Le découpage retenu est : [16, 25[, [25, 35[, [35, 45[, [45, 55[, [55, 65[, [65, 80].

Âge du véhicule (CarAge) Contrairement à une discrétisation classique en 3 tranches, un découpage plus granulaire est retenu après analyse graphique ($[0, 2[$, $[2, 5[$, $[5, 10[$, $[10, 15[$, $[15, 20]$), permettant de faire une étude plus fine dans la relation entre l'ancienneté et la sinistralité (ex. : effet des garanties constructeur sur les 2 premières années, dépréciation rapide).

Puissance du véhicule (Power) — regroupement par sévérité Une innovation méthodologique importante est introduite : le regroupement des modalités de **Power** est effectué non sur la *fréquence* (démarche standard), mais sur la **sévérité moyenne observée** dans la base attritionnelle. Cette approche est cohérente avec le rôle de la puissance dans la gravité des accidents plutôt que dans leur probabilité.

TABLE 1.5 – Regroupement de Power par sévérité moyenne attritionnelle

Groupe	Modalités	Sévérité moy. (approx.)
n-o	n, o	$\approx 957-1\,067$ EUR (basse)
d-e-f-g-k	d, e, f, g, k	$\approx 1\,176-1\,229$ EUR (moyenne)
h-i-j	h, i, j	$\approx 1\,242-1\,265$ EUR (moy-haute)
l-m	l, m	$\approx 1\,320-1\,365$ EUR (haute)

Choix méthodologique

Le regroupement de **Power** sur la sévérité plutôt que sur la fréquence est un choix délibéré fondé sur une réflexion collective au sein du groupe : la puissance du moteur est un proxy de la vitesse maximale et du coût de réparation du véhicule, deux facteurs qui influencent directement la *gravité* d'un accident plus que sa fréquence. Ce regroupement améliore la cohérence économique du modèle de sévérité.

Densité de population (Density) Relation croissante très nette entre densité et fréquence :

TABLE 1.6 – Fréquence annuelle par tranche de densité

Tranche (hab/km ²)	Fréquence annuelle
$[0, 100[$	0,0565
$[100, 500[$	0,0668
$[500, 1\,000[$	0,0754
$[1\,000, 5\,000[$	0,0905
$[5\,000, \infty[$	0,0912

Les zones très urbanisées (Paris et proche banlieue) présentent une sinistralité **61 % plus élevée** que les zones rurales, reflétant la densité du trafic.

Variables qualitatives La variable **Gas** montre une différence notable : Diesel (0,075) > Regular (0,066), les conducteurs Diesel parcourant généralement plus de kilomètres. La région Ile-de-France est la plus sinistrée (0,086) et le Centre la moins (0,064). Parmi les marques, les japonaises/coréennes (0,067) sont moins sinistrées que les allemandes/VW (0,081).

1.2.4 Analyse de corrélation et de liaison

1.2.4.1 Corrélations quantitatives (Pearson)

TABLE 1.7 – Matrice de corrélation de Pearson (variables continues)

	ClaimAmount	ClaimNb	DriverAge	CarAge	Exposure
ClaimAmount	1,000	0,012	−0,019	0,007	−0,035
ClaimNb	0,012	1,000	−0,022	−0,047	−0,008
DriverAge	−0,019	−0,022	1,000	−0,091	0,204
CarAge	0,007	−0,047	−0,091	1,000	−0,011
Exposure	−0,035	−0,008	0,204	−0,011	1,000

Les corrélations entre covariables restent très faibles ($|\rho| \leq 0,21$), limitant les risques de multicolinéarité dans les GLM. La corrélation entre **DriverAge** et **Exposure** (0,204) reflète le fait que les conducteurs âgés ont tendance à avoir des contrats plus anciens et donc une exposition plus élevée.

1.2.4.2 Mesure η^2 (liaison variable $\rightarrow$ sévérité)

Le coefficient η^2 mesure la proportion de variance du coût attritionnelle expliquée par chaque variable catégorielle :

$$\eta_j^2 = \frac{SS_{\text{inter}}^{(j)}}{SS_{\text{total}}} = \frac{\sum_k n_k (\bar{y}_k - \bar{y})^2}{\sum_i (y_i - \bar{y})^2}$$

TABLE 1.8 – η^2 de chaque variable qualitative sur **ClaimAmount** (base **basecoutattri2** — ordre décroissant)

Variable	η^2	η
CarAge	0,0016	0,0400
Region	0,0009	0,0300
Power	0,0007	0,0265
Brand	0,0007	0,0265
DriverAge	0,0005	0,0224
Density	0,0005	0,0224
Gas	0,0002	0,0141

Remarque

Les η^2 sont très faibles : la variance du coût d'un sinistre est principalement aléatoire. **CarAge** est la variable la plus associée à la sévérité ($\eta^2 = 0,0016$), suivi de **Region** ($\eta^2 = 0,0009$), ce que confirmera le stepAIC sur le GLM Gamma. **Power** et **Brand** sont à égalité ($\eta^2 = 0,0007$ chacun), motivant le regroupement de **Power** par sévérité plutôt que par fréquence. **Gas** reste quasi-insignifiant pour la sévérité ($\eta^2 = 0,0002$).

1.3 Construction de la base de données : fréquence et sévérité

1.3.1 Fusion des tables

La base de travail est construite par fusion de `freMTPLfreq` avec la sévérité agrégée par police : $\text{TotalClaim}_i = \sum_{j \in \text{police}_i} s_j$. Les polices sans sinistre reçoivent $\text{TotalClaim} = 0$.

1.3.2 Nettoyage complet des données

Le nettoyage comporte **six filtres successifs**, pour garantir la qualité des données modélisées :

- Filtre 1. Exposition > 1 an.** On exclut les **421 polices** avec $E_i > 1$, correspondant à des anomalies de saisie (une police ne peut couvrir plus d'une année d'exposition effective). Ces polices représentent $\approx 0,10\%$ du portefeuille.
- Filtre 2. Âge du véhicule > 20 ans.** On exclut les **5 934 véhicules** avec $\text{CarAge} > 20$ ans (valeurs jusqu'à 100 ans, manifestement pas très légales).
- Filtre 3. Nombre de sinistres négatif.** Vérification et suppression des éventuels $\text{ClaimNb} < 0$ (valeurs impossibles par construction pour un comptage).
- Filtre 4. Montant de sinistre nul ou négatif.** Suppression des $\text{ClaimAmount} \leq 0$ dans la base de sévérité, incompatibles avec la définition d'un sinistre indemnisé.
- Filtre 5. Densité de population nulle ou négative.** Suppression des polices avec $\text{Density} \leq 0$, correspondant à des erreurs de géolocalisation.
- Filtre 6. Âge du conducteur hors plage [16, 80] ans.** On exclut les conducteurs de moins de 16 ans (âge légal minimal) et de plus de 80 ans. Au-delà de 80 ans, les effectifs sont trop faibles pour estimer des prix fiables et les comportements de conduite sont peu représentatifs de la flotte assurée standard. Les bases fréquence et sévérité sont synchronisées via les `PolicyID` communs après ce filtre.

Remarque

Les filtres 3 à 6 ($\text{ClaimNb} < 0$, $\text{ClaimAmount} \leq 0$, $\text{Density} \leq 0$, DriverAge hors $[16, 80]$) constituent une amélioration par rapport à l'approche minimale (filtres 1 et 2 uniquement). Ils garantissent l'absence de valeurs aberrantes susceptibles de biaiser les estimations GLM, notamment les coefficients associés aux petites modalités.

1.3.3 Séparation sinistres attritionnels / atypiques (CAT)




FIGURE 1.1 – Seuil monétaire




FIGURE 1.2 – Coefficient de variation et coefficient d'asymétrie




FIGURE 1.3 – Proportion du coût total portée par les sinistres atypiques

La figure 1.1 traduit les quantiles en euros. On observe une inflexion marquée au-delà de $Q_{99\%}$: le seuil passe de $\approx 15\,000$ EUR à $\approx 65\,000$ EUR pour $Q_{99,5\%}$ puis $\approx 130\,000$ EUR pour $Q_{99,9\%}$.

La figure 1.2 illustre l'effet du seuil sur la forme de la distribution attritionnelle :

- le **skewness** (courbe bleue) explose au-delà de $Q_{99\%}$, signe que des sinistres extrêmes persistent dans l'attritionnel ;
- le **coefficient de Variation** (courbe orange) reste stable et inférieur à 1 jusqu'à $Q_{97,5\%}$ environ, puis s'emballe.

Un seuil à $Q_{97,5\%}$ maintient un skewness < 3 et un CV < 1 , garantissant une distribution attritionnelle compatible avec une loi Gamma.

La figure 1.3 montre que la part du coût atypique décroît rapidement avec le quantile : elle avoisine 50 % à $Q_{95\%}$ et tombe à 20 % pour $Q_{99,9\%}$. Un seuil à $Q_{97,5\%}$ capture environ 44 % du coût total dans la poche atypique, ce qui est à la fois significatif et raisonnable au vu de notre base de donnée.

1.3.3.1 choixmethodo

Après analyse conjointe des trois critères, le seuil de séparation est fixé au **quantile 97,5 %**. Ce choix plus conservateur que le $Q_{99,5\%}$ usuel présente trois avantages :

1. il intègre un volume plus important de sinistres extrêmes dans la surprime, améliorant la robustesse du modèle de sévérité ;
2. il garantit un skewness et un CV attritionnels compatibles avec une loi Gamma (skewness < 3 , CV < 1) ;
3. il isole une poche atypique qui concentre **44,15 %** du coût total, rendant la surprime matière à une tarification distincte.

Les **2,5 % de sinistres les plus coûteux** représentent **44,15 % du coût total** du portefeuille — illustration de la loi de Pareto en RC automobile.

Choix méthodologique

Le seuil de séparation est fixé au **quantile 97,5 %** (au lieu du quantile 99,5 % usuel). Ce choix plus conservateur est motivé par :

- Intégrer dans la surprime un volume plus important de sinistres extrêmes, difficilement modélisables par un GLM Gamma du fait de leur hétérogénéité.
- Améliorer la robustesse du modèle de sévérité en ne lui demandant de modéliser que les sinistres les plus « standard ».
- Refléter la réalité des portefeuilles RC où les sinistres graves (représentant les 2,5 % supérieurs) sont souvent gérés de façon distincte par les équipes techniques sinistres.

$$\text{Seuil} = Q_{97,5\%}(\text{ClaimAmount}) = \mathbf{7\,511 \text{ EUR}}$$

TABLE 1.9 – Séparation des sinistres attritionnels et atypiques

Base	Obs.	Part du coût	Description
basecoutattri	15 423	$\approx 55,85 \%$	Sinistres $\leq Q_{97,5\%}$
basecoutatyp	396	44,15 %	Sinistres $> Q_{97,5\%}$

Résultat clé

Les **2,5 % de sinistres les plus coûteux** représentent **44,15 % du coût total** du portefeuille. Ce chiffre illustre de façon saisissante la concentration extrême du risque en RC automobile : quelques sinistres graves (accidents mortels, traumatismes crâniens sévères, invalidités permanentes) dominent la charge sinistrale totale.

1.3.4 Surprime CAT

Les sinistres atypiques sont mutualisés sur l'ensemble du portefeuille via une surprime forfaitaire identique pour tous les contrats :

$$\hat{\pi}^{\text{CAT}} = \frac{\sum_{j: s_j > \text{seuil}} s_j}{n_{\text{polices}}} = \mathbf{37,02 \text{ EUR/police/an}}$$

Cette surprime s'ajoute à la prime pure attritionnelle ($\hat{\lambda}_i \times \hat{s}_i$) pour former la prime pure totale. Elle est **10,88 EUR supérieure** à la surprime obtenue avec le seuil à $Q_{99,5\%}$ (26,14 EUR), reflet du choix plus conservateur.

1.3.5 Recodage des variables

Pour stabiliser les estimations GLM et réduire le nombre de paramètres, les variables sont regroupées et discrétisées :

TABLE 1.10 – Regroupement des modalités et discrétisation

Variable	Avant recodage	Après recodage
Power	d, e, f, g, h, i, j, k, l, m, n, o	d-e-f-g-k h-i-j l-m n-o (groupé par sévérité moyenne)
Region	10 régions	C-B IDF PC-NPDC-AQUIT PDL-BN-HN-LIM
Brand	7 marques	Asian French Italy-Germany US
DriverAge	Continue [16, 80]	[16, 25[[25, 35[[35, 45[[45, 55[[55, 65[[65, 80]
CarAge	Continue [0, 20]	[0, 2[[2, 5[[5, 10[[10, 15[[15, 20]
Density	Continue	[min, 100[[100, 500[[500, 1k[[1k, 5k[[5k, max]

1.3.6 Modalités de référence

TABLE 1.11 – Modalités de référence retenues (identiques pour tous les GLM)

Variable	Référence	Justification
Power	d-e-f-g-k	Groupe le plus représenté (sévérité basse/moyenne)
CarAge	(5, 10]	Tranche la plus fréquente
DriverAge	(35, 45]	Conducteurs d'âge intermédiaire — sinistralité la plus faible
Brand	French	Marque dominante (Renault/Nissan/Citroën)
Gas	Diesel	Carburant majoritaire
Region	C-B	Centre-Bretagne
Density	[2, 100]	Zones rurales

1.3.7 Partitionnement apprentissage / test

La base recodée est divisée aléatoirement en proportion 80/20 avec `set.seed(123)`. L'appariement est réalisé par `PolicyID` pour éviter toute fuite d'information entre les deux ensembles.

TABLE 1.12 – Tailles des échantillons (base recodée après 6 filtres)

Base	Apprentissage (80 %)	Test (20 %)
basefreq2	322 111 polices	80 528 polices
basecoutattri2	12 257 sinistres	3 166 sinistres

1.4 Modélisation par GLM

1.4.1 Modélisation de la fréquence

1.4.1.1 Cadre théorique

Rappel théorique

Pour chaque police i , on modélise N_i (nombre de sinistres) en fonction de l'exposition E_i et d'un vecteur de covariables $\mathbf{x}_i$:

$$N_i \sim \mathcal{F}(\mu_i), \quad \log(\mu_i) = \underbrace{\log(E_i)}_{\text{offset}} + \beta_0 + \mathbf{x}_i^\top \boldsymbol{\beta}$$

Le terme *offset* $\log(E_i)$ (coefficient fixé à 1) ramène le comptage à un taux annualisé. L'interprétation est multiplicative : e^{β_j} = multiplicateur de fréquence pour la modalité j vs référence.

1.4.1.2 Modèle nul (*pois0*) et Poisson complet (*pois1*)

Le modèle sans covariables (**pois0**) estime directement la fréquence annuelle globale : $e^{\hat{\beta}_0} \approx 0,070$ sin/an.

Le modèle Poisson complet (**pois1**) avec toutes les variables confirme par ANOVA que chaque variable apporte une réduction significative de déviance. Les plus discriminantes sont **DriverAge** et **Density**.

1.4.1.3 Sélection backward stepAIC (*pois4* → *pois5*)

La procédure backward stepAIC sur la matrice de design complète identifie les variables indicatrices suivantes comme modèle optimal **pois5** :

Powerh-i-j | Powern-o | CarAge(10,15] | CarAge(15,20] | CarAge(2,5] | CarAge[0,2] |
DriverAge(45,55] | DriverAge[16,25] | BrandAsian | BrandItaly Germany | BrandUS |
GasRegular |
Density(100,500] | Density(500,1k] | Density(1k,5k] | Density(5k,27k] | Exposure

Remarque

Region est entièrement exclue du modèle final de fréquence : son effet géographique est sans doute capté par **Density**. La puissance n'est significative que pour les groupes extrêmes (h-i-j et n-o) par rapport au groupe de référence d-e-f-g-k.

1.4.1.4 Test de surdispersion et modèle Binomiale Négative (*nbinom1*)

Le GLM Poisson impose $\mathbb{E}[N_i] = \text{Var}[N_i]$. Le test de Cameron & Trivedi appliqué à **pois5** rejette l'équidispersion :

$$z = 6,18, \quad p = 3,18 \times 10^{-10}, \quad \hat{\phi} = 1,065 > 1 \implies \text{surdispersion confirmée}$$

On adopte la **Binomiale Négative** (**nbinom1**) avec la même formule que **pois5**. Elle introduit un paramètre de dispersion $\theta > 0$:

$$N_i \sim \mathcal{NB}(\mu_i, \theta), \quad \text{Var}[N_i] = \mu_i + \frac{\mu_i^2}{\theta}$$

1.4.1.5 Modèles à inflation de zéros (ZIP, ZINB, Hurdle)

La très forte proportion de zéros (> 96 %) motive l'examen de deux familles de modèles complémentaires :

Modèles Zero-Inflated (ZIP2, ZINB) Mélange d'une masse ponctuelle en 0 (assurés « structurellement » non-sinistrables) et d'une loi de comptage :

$$\mathbb{P}(N_i = 0) = \pi_i + (1 - \pi_i) \mathbb{P}_{\text{comptage}}(N_i = 0), \quad \text{logit}(\pi_i) = \mathbf{z}_i^\top \boldsymbol{\alpha}$$

La composante de comptage utilise CarAge, DriverAge, Brand, Gas, Density + offset. La composante d'inflation en 0 utilise Power, CarAge, DriverAge, Region, Density + offset.

Modèles Zéro Modifiés (ZMP2, ZMNB2) Séparation explicite entre : (1) la présence/absence de sinistre (régression logistique) et (2) le nombre de sinistres conditionnellement à $N_i \geq 1$ (Poisson ou BN tronqué en 0).

- Composante comptage : DriverAge, Brand, Region, Density + offset
- Composante présence : Power, CarAge, DriverAge, Brand, Gas, Region, Density + offset

1.4.1.6 Comparaison globale des modèles de fréquence

TABLE 1.13 – Critères d'adéquation de tous les modèles de fréquence (base apprentissage)

Modèle	Log-vrais.	AIC	BIC	Déviance
Poisson nul (pois0)	−53 136	106 274	106 285	81 988
Poisson complet (pois1)	−52 521	105 089	105 340	80 757
Poisson final (pois5)	−51 957	103 949	104 142	—
ZIP2	—	103 793	—	—
ZINB	—	103 795	—	—
Binomiale Négative (nbinom1)	−51 831	103 699	103 902	—
Hurdle Poisson (ZMP2)	—	104 725	—	—
Hurdle BN (ZMNB2)	—	104 717	—	—

Résultat clé

La **Binomiale Négative** (nbinom1) est le modèle retenu : AIC = 103 699, meilleur de tous les modèles testés. Le paramètre de surdispersion estimé $\hat{\theta} = 0,9528$ est significativement différent de $+\infty$, confirmant que la surdispersion est bien présente et bien captée. Les modèles Hurdle (ZMP2, ZMNB2), plus complexes, n'améliorent pas l'ajustement.

Vérification prédictive sur la base test

$$\sum_i \hat{N}_i^{\text{BN}} = 3\,143 \quad \text{vs} \quad \sum_i N_i^{\text{observé}} = 3\,252 \quad \Rightarrow \quad \text{écart} = 3,4 \%$$

La calibration globale est satisfaisante : le modèle Binomiale Négative sous-prédit légèrement le nombre total de sinistres sur la base test (3,4 % d'écart), ce qui reste acceptable compte tenu de la variabilité inhérente aux portefeuilles RC.

TABLE 1.14 – Principaux coefficients du modèle BN et leur interprétation

Coefficient	$\hat{\beta}$	$e^{\hat{\beta}}$	p-val
(Intercept)	-1,954	0,142	***
DriverAge[16,25]	+0,330	1,391	***
Density(5k,27k]	+0,296	1,344	***
Density(1k,5k]	+0,220	1,246	***
Density(500,1k]	+0,141	1,151	***
Density(100,500]	+0,082	1,085	***
BrandAsian	-0,159	0,853	***
GasRegular	-0,100	0,905	***
DriverAge(45,55]	+0,049	1,050	**
Powerh-i-j	+0,045	1,046	**
Powern-o	-0,062	0,940	*
CarAge[0,2]	+0,088	1,092	***
CarAge(2,5]	+0,031	1,031	*
CarAge(10,15]	-0,022	0,978	ns
CarAge(15,20]	-0,045	0,956	*
Exposure	-1,050	0,350	***

Coefficients du modèle Binomiale Négative (nbinom1)

Remarque

Lecture des multiplicateurs $e^{\hat{\beta}}$: le coefficient $-1,954$ de l'intercept donne une fréquence de référence $e^{-1,954} = 0,142$ sin/an pour le profil type (Power d-e-f-g-k, CarAge (5, 10], DriverAge (35, 45], Brand French, Diesel, Density [2, 100]). Les jeunes conducteurs [16,25] présentent un multiplicateur de 1,39 ($e^{+0,33}$), la zone très dense ajoute encore un facteur 1,34. Ces effets se combinent multiplicativement.

1.4.2 Modélisation de la sévérité

1.4.2.1 Cadre théorique

On modélise le coût individuel S_j des sinistres **attritionnels** ($S_j \leq Q_{97,5\%}$). Trois familles de lois sont comparées, toutes avec lien log :

TABLE 1.15 – Familles de lois testées pour la sévérité

Modèle	Distribution	Particularité
Gamma	$S_j \sim \Gamma(\alpha, \mu_j/\alpha)$	Queue légère, standard actuariel
Inverse Gaussienne	$S_j \sim \mathcal{IG}(\mu_j, \lambda)$	Queue plus lourde que Gamma
Log-normale	$\log(S_j) \sim \mathcal{N}(\mu_j, \sigma^2)$	OLS sur $\log(S)$, biais à corriger

1.4.2.2 Modèle Gamma — Sélection de variables (gamma4)

Le stepAIC both-direction sur la matrice de design complet retient comme modèle final **gamma4** :

CarAge[0,2] | CarAge(2,5] | CarAge(5,10] | CarAge(15,20] |
 DriverAge[16,25] | DriverAge(65,80] | BrandFrench | BrandItaly Germany | BrandUS |
 GasRegular | Density(1k,5k]

Remarque

La référence pour **CarAge** dans le modèle de sévérité est (10, 15] (exclu par le stepAIC — les véhicules de milieu de vie ont une sévérité typique). Les véhicules très récents ([0, 2]) et anciens ([15, 20]) présentent une sévérité distincte. La variable **Power** est exclue du modèle Gamma malgré son $\eta^2 = 0,0006$, mais son effet sera capté indirectement via le regroupement par sévérité réalisé en amont.

TABLE 1.16 – Principaux coefficients du modèle Gamma et multiplicateurs de sévérité

Coefficient	$\hat{\gamma}$	p-val
(Intercept)	+7,106	***
CarAge[0,2]	+0,051	**
CarAge(2,5]	+0,089	*
CarAge(5,10]	+0,051	*
CarAge(15,20]	−0,052	**
DriverAge[16,25]	+0,064	**
DriverAge(65,80]	+0,054	*
BrandFrench	−0,073	***
BrandItaly Germany	+0,051	**
BrandUS	−0,073	***
GasRegular	−0,022	*
Density(1k,5k]	+0,041	*

Coefficients du modèle Gamma (gamma4)

1.4.2.3 Modèle Log-normale — Sélection de variables (gauss2)

Le stepAIC both-direction sur $\log(\text{ClaimAmount})$ retient pour **gauss2** :

CarAge(15,20] | DriverAge(55,65] | DriverAge(65,80] | DriverAge[16,25] |
BrandFrench | BrandItaly Germany | BrandUS | GasRegular | Density(1k,5k]

La prédiction corrigée du biais de la transformation inverse est :

$$\hat{\mathbb{E}}[S_j] = \exp\left(\hat{\mu}_j + \frac{\hat{\sigma}^2}{2}\right)$$

1.4.2.4 Gaussienne Inverse (igauss4)

Pour assurer la convergence numérique, les coefficients initiaux de **igauss4** sont fixés à ceux du modèle Gamma (**start = coef(fit_gamma)**).

1.4.2.5 Comparaison des modèles de sévérité

TABLE 1.17 – Critères d'adéquation des modèles de sévérité (base attritionnelle apprentissage)

Modèle	Log-vrais.	AIC	BIC	RMSE test
Gamma (gamma4)	−98 787	197 601	—	1 021,08 EUR
Log-normale (gauss2)	−100 261	200 541	—	1 049,30 EUR
Gaussienne Inverse (igauss4)	−103 483	206 993	—	—

Résultat clé

Le modèle **Gamma (gamma4)** est le modèle final de sévérité retenu : AIC = 197 601 (vs 200 541 pour la Log-normale et 206 993 pour la Gaussienne Inverse), RMSE = 1 021,08 EUR sur la base test (vs 1 049,30 EUR pour la Log-normale). Il est également théoriquement cohérent pour des montants strictement positifs à queue asymétrique droite, caractéristiques des coûts attritionnels en RC automobile. La Gaussienne Inverse offre un AIC nettement moins bon (+9 392 vs Gamma).

1.5 Analyse des résultats

1.5.1 Calcul de la prime pure

La prime pure finale combine les deux modèles retenus selon :

$$\hat{\Pi}_i = \hat{\lambda}_i \times \hat{s}_i + 37,02 \text{ EUR}$$

Profil de référence Le profil de référence correspond à : Power **d-e-f-g-k**, CarAge (5, 10], DriverAge (35, 45], Brand French, Gas Diesel, Region C-B, Density [2, 100].

$$\hat{\lambda}_{\text{ref}} = e^{-1,954} = 0,1418 \text{ sin/an} \quad (1.1)$$

$$\hat{s}_{\text{ref}} = \exp(\text{prédiction Gamma profil réf.}) = 1\,199,92 \text{ EUR} \quad (1.2)$$

$$\hat{\Pi}_{\text{ref}} = 0,1418 \times 1\,199,92 + 37,02 = 170,11 + 37,02 = \boxed{207,13 \text{ EUR/an}} \quad (1.3)$$

TABLE 1.18 – Prime pure selon le profil de risque

Profil	Caractéristiques	Fréquence	Prime pure
Référence	d-e-f-g-k, (5,10], (35,45], French, Diesel, C-B, [2,100]	0,142 sin/an	207,13 EUR
Risqué	+ Jeune [16, 25] + Zone dense (5k, 27k] + Puissant h-i-j	$\approx 0,290$	$\approx 390 \text{ EUR}$
Favorable	+ Marque Asian + Véhicule [15, 20]	$\approx 0,119$	$\approx 173 \text{ EUR}$

Profils contrastés

Remarque

La surprime CAT de **37,02 EUR/police** est nettement plus élevée que dans la version précédente (26,14 EUR avec $Q_{99,5\%}$), reflétant le choix plus conservateur du seuil à $Q_{97,5\%}$. Toutes choses égales par ailleurs, cela augmente la prime pure totale d'environ **11 EUR** pour tous les profils.

1.5.2 Synthèse des choix méthodologiques

TABLE 1.19 – Bilan des améliorations méthodologiques par rapport à l'approche standard

Aspect	Approche standard	Approche améliorée
Filtres nettoyage	Exposure > 1, CarAge > 20	+ ClaimNb < 0, ClaimAmount ≤ 0, Density ≤ 0, DriverAge hors [16, 80]
Seuil CAT	$Q_{99,5\%}$	$Q_{97,5\%}$
Groupe Power	Par fréquence	Par sévérité (4 groupes)
Tranches DriverAge	5 tranches [18, 99]	6 tranches [16, 80]
Tranches CarAge	3 tranches ([0, 3], (3, 11], (11, 20])	5 tranches (plus granulaire)
Référence Power	e-f	d-e-f-g-k
Référence DriverAge	(30, 45]	(35,45]
Référence CarAge	(3, 11]	(5,10]

1.5.3 Synthèse comparative des modèles retenus

TABLE 1.20 – Récapitulatif de la sélection des modèles

Composante	Modèle retenu	AIC	Raison principale
Fréquence	BN (nbinom1)	103 699	Meilleur AIC/BIC, gère la surdispersion ($\hat{\theta} = 0,95$)
Sévérité	Gamma (gamma4)	197 601	Meilleur AIC et RMSE test (1 021 EUR)
Atypiques	Surprime forfaitaire	—	37,02 EUR/police ($Q_{97,5\%}$)

Récapitulatif chiffré final

Taille portefeuille (après filtrage)	402 639 polices
Seuil sinistres atypiques ($Q_{97,5\%}$)	7 490,75 EUR
Part coût atypiques	44,15 % du coût total
Surprime CAT	37,02 EUR/police/an
Fréquence annuelle globale	0,0705 sinistre/an
Sévérité attritionnelle moyenne	1 222,6 EUR
Groupe Power	par sévérité (4 groupes : n-o, d-e-f-g-k, h-i-j, l-m)
Modèle fréquence retenu (AIC)	Binomiale Négative — AIC = 103 699
Modèle sévérité retenu (AIC)	Gamma — AIC = 197 601
Prime pure profil de référence	207,13 EUR/an ($\hat{\lambda} = 0,142$, $\hat{s} = 1 220$ EUR)

1.6 Limites et perspectives

1.6.1 Limites de l'approche GLM

- Hypothèse log-linéaire stricte.** Même avec un découpage plus fin (5 tranches CarAge, 6 tranches DriverAge), le GLM suppose une relation log-linéaire constante au sein de chaque tranche. Les effets non-linéaires intra-tranche subsistent et ne peuvent être captés qu'avec des splines ou des GAM.

2. **Absence d'interactions automatiques.** Le modèle additif ignore les effets croisés : un jeune conducteur ([16, 25]) avec un véhicule puissant (h-i-j) en zone très dense ($> 5\,000$ hab/km²) est-il plus risqué que la somme des trois effets individuels ? Le GLM ne le capte pas sans ajout manuel d'interactions.
3. **Sensibilité au choix du seuil CAT.** Le passage de $Q_{99,5\%}$ à $Q_{97,5\%}$ augmente la surprime de 26 à 37 EUR (+42 %) et modifie le périmètre du modèle de sévérité. Ce choix doit être validé par les équipes techniques sinistres.
4. **Cohérence du groupement Power entre les deux modèles.** Utiliser un regroupement de Power basé sur la sévérité pour les deux modèles (fréquence et sévérité) peut créer une légère incohérence : le groupement optimal pour la fréquence pourrait être différent. Idéalement, deux grilles de recodage distinctes devraient être utilisées.
5. **Exclusion des conducteurs > 80 ans.** Ce filtre améliore la robustesse mais crée un biais de sélection : le portefeuille modélisé ne représente pas exactement la population totale. Une alternative serait de conserver ces polices dans la tranche [65, 80].
6. **Absence de variables comportementales.** Kilométrage, historique individuel de sinistres, données de conduite connectée (télématique) : ces informations très prédictives ne sont pas disponibles dans les données CASdatasets.
7. **Stabilité temporelle.** Le modèle est estimé sur une coupe transversale. L'évolution du mix portefeuille (montée des véhicules électriques, changements de comportement de conduite) peut invalider les relativités tarifaires à moyen terme.

1.6.2 Perspectives

- **GAM** : modèles additifs généralisés avec splines, capturant les non-linéarités (courbe en U de l'âge du conducteur) tout en conservant l'interprétabilité graphique.
- **Gradient Boosting (XGBoost/LightGBM)** : capture automatique des interactions et des effets non-linéaires, excellent pouvoir prédictif sur des données tabulaires.
- **CANN (Combined Actuarial Neural Network)** : architecture qui superpose un réseau de neurones au GLM, garantissant que le réseau ne dégrade pas les prédictions si ses effets sont nuls.
- **GPD pour les sinistres extrêmes** : remplacer la surprime forfaitaire par un modèle de Pareto Généralisé sur la queue ($> Q_{97,5\%}$), permettant une modélisation paramétrique des sinistres graves.
- **Double grille de recodage Power** : utiliser un regroupement par fréquence pour le modèle Poisson/BN et un regroupement par sévérité pour le modèle Gamma, maximisant la cohérence de chaque composante.

Chapitre 2

Tarification par Machine Learning

2.1 Estimation de la fréquence

2.1.1 Résumé

Dans cette partie nous estimons la fréquence par machine learning en tenant compte du déséquilibre de classes dans notre modélisation. En effet, la variable `ClaimNb` présente un fort déséquilibre de classe avec une très importante partie de ses observations qui prennent la valeur 0 dans notre base de fréquence notée *basefreq2*.

Pour pallier ce problème, nous utilisons donc des méthodes de rééchantillonnage préférentiel tenant compte du déséquilibre de classes afin d'effectuer un prétraitement des données avant de les combiner à nos modèles de machine learning.

Notons également que certaines métriques tels que l'**Accuracy** deviennent trompeuses, voir inutiles dans la décision finale du modèle à retenir, dû au fort déséquilibre de classes qui caractérise notre jeu de données.

2.1.2 Gestion du déséquilibre des classes

2.1.2.1 Problématique

Le déséquilibre de notre base de données *basefreq2*, entraîne une sur-estimation de la modalité 0 dans notre fréquence.

En effet, bien que la variable `ClaimNb` $\in \llbracket 0, 4 \rrbracket$, l'analyse de la variable montre que 96,3% des observations prennent la valeur 0. Une simple estimation de la fréquence par machine learning sous estimerait donc énormément la fréquence réelle sur notre jeu de données (et par conséquent la prime, qui risquerait d'atteindre des valeurs quasi-nulles).




FIGURE 2.1 – Distribution de la variable `ClaimNb`

La gestion des données déséquilibrées représentant une problématique centrale en data science, plusieurs méthodes de rééchantillonnage préférentiel s'offrent à nous.

2.1.2.2 Utilisation de méthodes de rééchantillonnage préférentiel

Les méthodes de rééchantillonnage préférentiel visent à corriger le déséquilibre de classes en modifiant artificiellement la distribution des données d'entraînement pour que le modèle accorde plus d'attention à la classe minoritaire, en l'occurrence les polices sinistrées qui ne représentent que 3,7% de la base.

La méthode **SMOTE** crée synthétiquement de nouvelles observations de la classe minoritaire par interpolation entre observations existantes via l'algorithme des **k plus proches voisins**, tandis que **SMOTEENN** combine cette sur-représentation avec un nettoyage des observations ambiguës aux frontières de décision. La pondération par **class_weight** ou **scale_pos_weight** adopte une approche différente sans modifier les données : elle pénalise davantage les erreurs commises sur la classe minoritaire dans la fonction de perte, forçant le modèle à mieux apprendre les profils sinistrés même en présence d'un fort déséquilibre.




FIGURE 2.2 – Comparaison de la distribution de ClaimNb avant et après rééchantillonnage

Notons que malgré le fait que $\text{ClaimNb} \in \llbracket 0, 4 \rrbracket$, nous ne représentons que 2 classes, la classe 0 correspondant à la modalité 0, et la classe 1 correspondant à toutes les modalités $\text{ClaimNb} > 0$, en effet la variable a été binarisée dans cette opération car l'objectif final est d'estimer une fréquence de sinistres et les modalités 2,3 et 4 étant trop rares (moins de 1% des observations) pour être jugées pertinentes à étudier séparément.

2.1.3 Méthodes de machine learning combinées au rééchantillonnage

Plusieurs modèles de machine learning (**LightGBM**, **XGBoost**, **Random Forest**, **Gradient Boosting classique...**), ont été combinés à nos méthodes de rééchantillonnage et de pondération des classes citées précédemment afin d'obtenir de meilleures estimations.

Le choix du bon modèle s'est basé sur les métriques généralement utilisées en classification (sauf l'**Accuracy** qui est biaisée par une surreprésentation initiale de la classe 0, nous faisons donc face au fameux "*paradoxe de l'Accuracy*", qui nous empêche d'exploiter cette métrique dans notre analyse).

Nous obtenons donc les résultats suivants après entraînement pour les modèles les plus pertinents :

TABLE 2.1 – Tableau comparatif des modèles de fréquence — Gestion du déséquilibre

Modèle	ROC-AUC	PR-AUC	Recall-1	TP	FN
LightGBM + class_weight	0.6516	0.0610	0.6842	2104	971
XGBoost + scale_pos_weight	0.6483	0.0608	0.6709	2063	1012
LightGBM + SMOTE	0.6308	0.0555	0.2423	745	2330
LightGBM + SMOTEENN	0.6014	0.0532	0.1502	462	2613
RandomForest + sample_weight	0.5665	0.0458	0.2130	655	2420




FIGURE 2.3 – Courbes ROC et Recall des différents modèles après gestion du déséquilibre

Un autre choix central dans notre étude est le choix du seuil de décision, permettant d'effectuer un arbitrage sur la proportion de sinistres à modéliser ainsi que sur l'évolution de la **Precision** et du rappel (**Recall**). Le F1-Score quant à lui est une moyenne harmonique de la précision et du rappel et évalue l'équilibre entre ces deux grandeurs dans un modèle.

Notre seuil sera donc choisit pour maximiser le **F1-Score**, ainsi comme nous l'observons ci-dessous la valeur du seuil retenu comme paramètre pour améliorer nos modèles de machine learning combinés au déséquilibre des classes est de 0,59.




FIGURE 2.4 – Détermination du seuil optimal à l'aide du F1-Score

Les résultats et le choix du modèle final seront exposés dans le **3.1.1 Prédiction de la fréquence**.

2.2 Estimation du coût

2.2.1 Résumé

Contrairement à l'approche GLM de référence, la séparation entre sinistres attritionnels et sinistres atypiques n'a pas été fixée ici à partir d'un simple quantile choisi *a priori*. Nous avons adopté une démarche plus empirique, fondée à la fois sur l'analyse de la distribution des coûts, sur des méthodes d'isolement de valeurs aberrantes, et sur l'étude de la queue par la théorie des valeurs extrêmes. Cette approche a permis de retenir un seuil plus cohérent avec la structure réelle des données.

La méthodologie s’est ensuite organisée en plusieurs étapes. Les sinistres ont d’abord été séparés entre une composante *attritionnelle*, correspondant aux sinistres courants, et une composante *atypique*, beaucoup plus rare mais nettement plus lourde. Les coûts attritionnels ont ensuite été modélisés par plusieurs méthodes de machine learning afin d’évaluer si les variables disponibles permettaient de mieux prédire la sévérité qu’une simple moyenne de portefeuille. Les sinistres atypiques ont été traités dans un cadre hybride, combinant théorie des valeurs extrêmes et modèles de machine learning, afin de concilier lecture actuarielle de la queue et prédiction individuelle. Enfin, une modélisation de la probabilité d’être atypique a été introduite pour combiner les différentes composantes du coût.

Cette démarche présente un intérêt pratique clair : elle permet de ne pas traiter de la même manière des sinistres très différents en fréquence, en niveau de coût et en stabilité statistique. Elle met aussi en évidence les limites des approches avancées lorsque les bases sont peu riches en information. Dans notre cas, les gains obtenus sont restés modestes sur les attritionnels, mais plus visibles sur la composante atypique.

En revanche, les résultats montrent également qu’une intégration directe du coût atypique dans le coût moyen final peut conduire à des niveaux de prime trop élevés au regard d’un objectif de tarification concurrentielle. Cela conduit à privilégier, à ce stade, une utilisation plus prudente de cette composante, sous forme de surcharge ou de composante crédibilisée, plutôt que comme une espérance pleine directement injectée dans le coût moyen.

2.2.2 Analyse des sinistres attritionnels

2.2.2.1 Objectif et logique de modélisation

L’objectif de cette partie était d’estimer le coût moyen des sinistres attritionnels en fonction des variables tarifaires disponibles. Dans cette population, la question centrale était de savoir si les caractéristiques du contrat et du profil assuré permettaient de prédire finement le montant du sinistre, ou si la sévérité restait essentiellement homogène autour d’un niveau moyen.

L’analyse descriptive a montré que les sinistres attritionnels présentent une asymétrie à droite, mais restent beaucoup plus réguliers que les atypiques. La transformation logarithmique du coût améliore la forme de distribution, ce qui justifiait des essais de modélisation à la fois sur coût brut et sur $\log(1 + \text{coût})$. Plusieurs familles de modèles ont donc été testées :

- des baselines simples (moyenne et médiane du portefeuille) ;
- des modèles d’ensemble de type *Random Forest* ;
- des modèles de *Gradient Boosting* ;
- des variantes plus performantes de boosting, notamment *XGBoost* et *LightGBM* ;
- des essais avec et sans interactions explicites entre variables tarifaires.

Le but n’était pas de multiplier arbitrairement les modèles, mais de répondre à une question simple : les variables disponibles apportent-elles une information suffisante pour faire significativement mieux qu’une prédiction constante ?

2.2.2.2 Critères de comparaison et sélection du modèle

Les modèles ont été comparés à l’aide de plusieurs critères :

- le **RMSE**, pour mesurer l’écart quadratique moyen et pénaliser les erreurs importantes ;
- le **MAE**, plus robuste et plus lisible pour des coûts en euros ;
- le **MAPE tronqué**, utilisé à titre complémentaire pour apprécier l’erreur relative sans donner trop de poids aux très petites valeurs ;
- la comparaison entre **moyenne observée** et **moyenne prédite**, afin de vérifier l’absence de biais trop marqué.

Le résultat principal est que la plupart des modèles sophistiqués se sont révélés très proches, voire légèrement moins bons, que la simple moyenne globale. Parmi les modèles de machine learning, **XGBoost sur coût brut** a été le plus convaincant, avec des performances quasi identiques à la baseline moyenne. Ce point est important : il ne signifie pas que le machine learning est inutile, mais plutôt que les variables disponibles contiennent peu d'information réellement discriminante pour expliquer le coût attritionnel individuel.

2.2.2.3 Résultats et interprétation pratique

En pratique, l'analyse conduit à deux conclusions. Premièrement, la composante attritionnelle du coût est relativement stable, ce qui explique qu'un estimateur simple fasse déjà très bien le travail. Deuxièmement, le fait que *XGBoost* atteigne un niveau presque équivalent à la moyenne laisse penser qu'avec une base plus riche en variables pertinentes, ce type de modèle pourrait devenir plus performant.

Dans le cadre présent, nous retenons donc **XGBoost comme meilleur modèle de machine learning pour les attritionnels**, non parce qu'il bat nettement la moyenne, mais parce qu'il est le plus proche de cette référence tout en offrant une structure prédictive plus flexible et potentiellement plus exploitable si les données étaient enrichies. Ce choix reste néanmoins prudent : il ne doit pas être interprété comme une preuve que la sévérité attritionnelle est finement modélisée, mais plutôt comme le meilleur compromis entre sophistication et stabilité parmi les méthodes testées.




FIGURE 2.5 – Distribution brute et distribution transformée des sinistres attritionnels.

	model	RMSE	MAE	MAPE_trim50	Mean_true	Mean_pred
0	Baseline_mean	904.543702	520.115223	1.888146	1190.708659	1200.194302
1	XGB_raw_base	905.309478	552.248120	1.899917	1190.708659	1197.760254
2	Baseline_median	905.321872	511.784831	1.805473	1190.708659	1152.000000
3	HGB_log_base	908.906508	551.448535	1.867204	1190.708659	1193.835332
4	HGB_log_interactions	909.064275	551.644278	1.863578	1190.708659	1193.222436
5	GBR_raw_base	910.903570	563.274291	1.910552	1190.708659	1198.703466
6	LGBM_raw_base	911.566190	562.955337	1.912393	1190.708659	1200.216247
7	RF_log_base	913.006591	558.996300	1.812228	1190.708659	1162.690435
8	XGB_log_base	916.935894	570.207215	1.851898	1190.708659	1179.879272
9	XGB_log_interactions	921.000162	574.850291	1.854003	1190.708659	1176.941284
10	GBR_log_base	924.102131	579.928166	1.847511	1190.708659	1174.448860
11	LGBM_log_base	925.736370	580.882768	1.842139	1190.708659	1169.465676
12	GBR_log_interactions	929.013977	586.225632	1.847199	1190.708659	1166.991231
13	LGBM_log_interactions	929.915162	586.055777	1.847418	1190.708659	1165.629084

FIGURE 2.6 – Comparaison des modèles testés sur la sévérité attritionnelle.

2.2.3 Traitement des sinistres atypiques

2.2.3.1 Volumétrie et justification d'un traitement séparé

Les sinistres atypiques représentent une faible part des observations, mais une part disproportionnée du coût total. Leur distribution est extrêmement asymétrique, avec une queue lourde et une forte instabilité des moments usuels. Dans ce contexte, la moyenne seule devient difficile à interpréter et peut être dominée par un très petit nombre de dossiers extrêmes.

Cette configuration justifie pleinement un traitement séparé. L'objectif n'était pas seulement de prédire un coût moyen, mais aussi de comprendre la structure de la queue, d'évaluer la pertinence d'un cadre EVT (*Extreme Value Theory*), puis de vérifier si des modèles de machine learning pouvaient apporter une amélioration sur la prédiction individuelle.

2.2.3.2 Étape EVT / GPD

Les excès au-dessus du seuil retenu ont été étudiés à l'aide d'une loi de Pareto généralisée (GPD). Cette étape avait trois objectifs :

- confirmer que la queue des atypiques relève bien d'une logique de valeurs extrêmes ;
- disposer d'une référence actuarielle pour quantifier les niveaux élevés de coût ;
- éviter d'utiliser sans recul une moyenne brute très instable.

L'ajustement GPD a validé la lourdeur de la queue et fourni des repères utiles, notamment sur les quantiles élevés. En revanche, l'espérance directe issue de la GPD s'est révélée trop instable pour être utilisée seule comme coût atypique moyen. Cette limite est importante en pratique : un bon ajustement de queue ne suffit pas à produire une estimation tarifaire exploitable.

2.2.3.3 Modélisation machine learning des atypiques

En parallèle de l'approche EVT, plusieurs modèles de machine learning ont été testés sur les coûts atypiques, en travaillant sur le **logarithme de l'excès au-dessus du seuil**. Ce choix est motivé par la nécessité de stabiliser une distribution extrêmement dissymétrique. Les principaux modèles évalués ont été :

- Random Forest ;
- HistGradientBoosting ;
- Gradient Boosting ;
- XGBoost ;
- LightGBM.

Les modèles ont été comparés à la fois sur des critères de prédiction individuelle (RMSE, MAE, MedAE) et sur leur capacité à reproduire certains niveaux de queue. Les résultats ont montré que **XGBoost sur log-excès** était le meilleur modèle prédictif individuel parmi les méthodes testées. Il améliore sensiblement les baselines simples et surpasse aussi une utilisation purement globale de l'EVT en termes de qualité de prédiction dossier par dossier.

2.2.3.4 Modèle retenu et logique hybride

Même si *XGBoost* est le meilleur modèle individuel, il reste encore insuffisant pour reproduire parfaitement la haute queue. À l'inverse, l'EVT décrit mieux certains niveaux extrêmes, mais tend à devenir trop instable si on l'utilise directement comme prédicteur global. C'est pourquoi la solution retenue a été une **combinaison hybride** entre :

- la prédiction individuelle fournie par **XGBoost** ;

— un ancrage de prudence issu de la **GPD**, au travers du quantile 95 %.

La pondération retenue a conduit à une combinaison majoritairement portée par la prédiction *XGBoost*, complétée par une faible composante EVT. Cette construction permet de limiter la sous-estimation de la queue sans faire exploser artificiellement le coût atypique moyen.

2.2.3.5 Implication pratique

La conséquence pratique est que la composante atypique peut être estimée de manière plus crédible qu’avec une simple moyenne ou qu’avec une GPD brute, mais elle reste une composante *fragile* du tarif. Elle doit donc être manipulée avec prudence : les résultats sont utiles pour hiérarchiser le risque et construire une charge extrême, mais pas nécessairement pour imposer directement un niveau de prime complet sans ajustement complémentaire.




FIGURE 2.7 – Distribution brute et distribution transformée des sinistres atypiques.




FIGURE 2.8 – Diagnostics EVT sur les excès atypiques.

Coût moyen atypique observé : 33319.03470715835
 Coût moyen préd. XGB : 22810.271484375
 Coût moyen préd. hybride : 30956.7578125

FIGURE 2.9 – Comparaison des modèles de prédiction des sinistres atypiques.

2.2.4 Prédiction de la probabilité d’avoir un sinistre attritionnel ou atypique

2.2.4.1 Idée et utilité pratique

Une fois les deux composantes de coût modélisées séparément, il reste à estimer la probabilité qu’un sinistre observé appartienne à la classe attritionnelle ou à la classe atypique. Cette étape est indispensable, car elle permet ensuite de pondérer correctement les deux niveaux de coût estimés.

D’un point de vue pratique, cette probabilité joue un rôle très important : elle sert d’interface entre la composante régulière du coût et la composante extrême. Sans elle, on serait obligé soit d’ignorer le risque atypique, soit de l’intégrer de manière uniforme à tous les assurés, ce qui serait peu réaliste.

2.2.4.2 Méthodologie et modèles testés

La base combinée a été construite en réunissant les sinistres attritionnels et atypiques, avec une variable binaire indiquant l’appartenance à la classe atypique. Plusieurs classifieurs ont ensuite été testés :

- une baseline fondée sur le taux global d’atypiques ;
- une régression logistique ;
- Random Forest ;
- HistGradientBoosting ;
- XGBoost ;
- LightGBM ;
- des versions enrichies par certaines interactions explicites.

Les modèles ont été comparés à partir de trois critères complémentaires :

- l’**AUC**, pour la capacité de discrimination ;
- la **LogLoss**, pour la qualité probabiliste ;
- le **Brier score**, pour la calibration.

2.2.4.3 Modèle retenu

Le modèle retenu est **HistGradientBoostingClassifier** sur les variables de base. Ce choix repose sur deux arguments principaux. D’une part, il est celui qui obtient le meilleur compromis entre capacité de classement et qualité probabiliste. D’autre part, sa probabilité moyenne prédite reste très proche du taux atypique observé, ce qui est essentiel dans une perspective de tarification.

Ce point est particulièrement important : plusieurs modèles plus complexes donnaient des probabilités moyennes beaucoup trop élevées, ce qui aurait conduit à surcharger excessivement la composante atypique dans le coût final. Le modèle retenu a donc été privilégié non seulement pour sa performance statistique, mais aussi pour sa cohérence actuarielle.

	model	AUC	LogLoss	Brier	Rate_true	Rate_pred
0	HGB_base	0.628413	0.127918	0.027881	0.029077	0.029320
1	HGB_interactions	0.619746	0.128607	0.027883	0.029077	0.029201
2	Logistic_interactions	0.619003	0.637602	0.222983	0.029077	0.440283
3	Logistic_base	0.609870	0.644864	0.226295	0.029077	0.448622
4	RF_interactions	0.593396	0.526936	0.170034	0.029077	0.397507
5	XGB_interactions	0.591953	0.517437	0.171863	0.029077	0.366453
6	RF_base	0.591171	0.484036	0.150852	0.029077	0.367634
7	XGB_base	0.590456	0.536220	0.179266	0.029077	0.382732
8	LGBM_base	0.588085	0.465406	0.149859	0.029077	0.332678
9	LGBM_interactions	0.564248	0.441418	0.140477	0.029077	0.310008
10	Baseline_rate	0.500000	0.131519	0.028232	0.029077	0.029161

FIGURE 2.10 – Comparaison des modèles de probabilité d'appartenance à la classe atypique.

2.2.5 Prédiction du coût total

2.2.5.1 Principe général

Une fois les trois briques précédentes disponibles

$$\hat{C}_{attr}(x), \quad \hat{C}_{atyp}(x), \quad \hat{p}_{atyp}(x),$$

il devient possible de construire une estimation globale du coût attendu par sinistre.

L'idée initiale était d'utiliser une formule de mélange de type

$$\hat{C}_{total}(x) = (1 - \hat{p}_{atyp}(x))\hat{C}_{attr}(x) + \hat{p}_{atyp}(x)\hat{C}_{atyp}(x).$$

Cette écriture est naturelle du point de vue probabiliste, puisqu'elle correspond à une espérance conditionnelle. Toutefois, les essais réalisés ont montré qu'une telle intégration directe de la composante atypique peut conduire à des coûts moyens trop élevés. En effet, même avec une probabilité atypique faible, le simple produit $\hat{p}_{atyp} \times \hat{C}_{atyp}$ devient vite important dès que $\hat{C}_{atyp}$ est lui-même très élevé.

2.2.5.2 Pondération et logique de combinaison

Pour éviter ce problème, la composante atypique a été traitée de manière prudente. Une première pondération a été introduite à l'intérieur du coût atypique lui-même, via une combinaison convexe entre la prédiction *XGBoost* et le quantile 95 % issu de la GPD :

$$\hat{C}_{atyp}^{hyb}(x) = \alpha \hat{C}_{XGB}(x) + (1 - \alpha) Q_{95}^{EVT},$$

avec une valeur de α choisie empiriquement sur la base des performances observées. La pondération retenue a été majoritairement en faveur de *XGBoost*, ce qui signifie que l'information individuelle reste au coeur du modèle, tandis que la composante EVT agit comme correctif de prudence.

	model	alpha	RMSE	MAE	MedAE	Mean_true	Mean_pred
0	Hybrid_XGB_Q95EVT_alpha_0.90	0.9	37322.965201	25459.736601	18090.388672	25630.0	29432.501953
1	Hybrid_XGB_Q95EVT_alpha_1.00	1.0	37495.671489	21062.072539	11347.644531	25630.0	21360.562500
2	Hybrid_XGB_Q95EVT_alpha_0.80	0.8	38896.480142	30769.204763	26374.140625	25630.0	37504.445312
3	Hybrid_XGB_Q95EVT_alpha_0.70	0.7	42020.502125	36735.794355	33646.203125	25630.0	45576.382812
4	Hybrid_XGB_Q95EVT_alpha_0.60	0.6	46382.789920	42745.611433	41805.371094	25630.0	53648.332031
5	Hybrid_XGB_Q95EVT_alpha_0.50	0.5	51670.666420	48755.427251	49941.617188	25630.0	61720.261719
6	Hybrid_XGB_Q95EVT_alpha_0.40	0.4	57629.909131	54946.422253	58479.585938	25630.0	69792.195312
7	Hybrid_XGB_Q95EVT_alpha_0.30	0.3	64073.464017	61388.774950	67282.335938	25630.0	77864.132812
8	Hybrid_XGB_Q95EVT_alpha_0.20	0.2	70869.358475	67953.525202	76121.773438	25630.0	85936.078125
9	Hybrid_XGB_Q95EVT_alpha_0.10	0.1	77925.453343	74862.193128	84352.296875	25630.0	94008.007812
10	Hybrid_XGB_Q95EVT_alpha_0.00	0.0	85177.119772	82054.610299	92274.960938	25630.0	102079.953125

Meilleur alpha selon RMSE : 0.9

FIGURE 2.11 – Dispersion des prédictions totales par rapport aux coûts observés.

En revanche, l'intégration finale de cette composante atypique dans le coût total appelle une grande prudence. Les résultats obtenus montrent qu'une utilisation directe de $\hat{p}_{atyp}(x)\hat{C}_{atyp}^{hyb}(x)$ peut encore conduire à des niveaux de coût peu compatibles avec un tarif concurrentiel.

Chapitre 3

Synthèse

3.1 Analyse et comparaison des résultats avec la méthode GLM

3.1.1 Prédiction de la fréquence

Au vu de ce qui a été présenté précédemment dans le **2.1 Estimation de la fréquence**. Nous obtenons les résultats suivants pour le profil de référence :

TABLE 3.1 – Fréquence estimée par modèle ML — Profil de référence

Modèle	Probabilité (%)
LightGBM + class_weight	49.64%
XGBoost + scale_pos_weight	50.78%
LightGBM + SMOTE	28.93%
LightGBM + SMOTEENN	16.45%
RandomForest + sample_weight	0.00%
<i>Référence GLM (BN)</i>	<i>14.18%</i>

Au vu des métriques obtenues et des résultats précédents, le modèle **LightGBM + SMOTEENN** est retenu comme modèle de fréquence ML car il produit une probabilité de sinistre de 16.45% pour le profil de référence, soit l'estimation la plus proche de la fréquence de référence de 14.18% obtenue par le GLM Binomiale Négative. Bien que son **ROC-AUC** soit légèrement inférieur aux modèles avec pondération, sa cohérence tarifaire est nettement supérieure, ce qui constitue le critère déterminant en actuariat.

Egalement en analysant l'impact de chaque modalité sur la fréquence estimée par le modèle LightGBM + SMOTEENN (en comparaison au profil de référence) nous obtenons les résultats suivants qui attestent de la cohérence de notre choix :




FIGURE 3.1 – Evolution de la fréquence estimée par le modèle en fonction des modalités

A titre de comparaison, la fréquence estimée de façon "naive" par machine learning sans tenir compte du déséquilibre des classes était inférieure à 1% et cette valeur évoluait légèrement à 4.45% lorsqu'on couplait ces modèles de machine learning à des GLM (toujours sans tenir compte du déséquilibre).

La gestion du déséquilibre a donc été un point essentiel dans notre estimation fréquentielle.

3.1.2 Prédiction du coût

3.1.2.1 Résultats obtenus et interprétation

Les comparaisons entre coûts observés et coûts prédits montrent un résultat contrasté :

- le **niveau moyen global** est correctement reproduit ;
- la **distribution prédite** reste toutefois plus lissée que la distribution observée ;
- les quantiles centraux sont souvent surestimés, alors que la queue la plus élevée est sous-estimée ;
- les écarts par segment montrent que certains groupes restent mal restitués, malgré la structuration en classes.




FIGURE 3.2 – Comparaison entre les coûts observés et les coûts prédits





FIGURE 3.3 – Dispersion des prédictions totales par rapport aux coûts observés.



Comparaison par DriverAge_cls

	DriverAge_cls	n_obs	mean_obs	mean_pred	median_obs	median_pred	rel_gap_mean
4	Jeunes conducteurs [16-30]	3090	3204.161489	2174.561399	1153.0	2057.378076	-0.321332
2	Conducteurs seniors [60-80]	2170	2179.654839	2096.259685	1165.0	1926.801229	-0.038261
0	Conducteurs expérimentés [30-40]	3449	1923.411714	2030.283818	1150.0	1913.797765	0.055564
1	Conducteurs mûrs [40-50]	4048	1761.340415	2030.845330	1154.0	1912.953490	0.153011
3	Conducteurs seniors actifs [50-60]	3061	1753.628226	2033.423807	1158.0	1919.300592	0.159552

FIGURE 3.4 – Analyse des écarts de prédiction globaux et par segment

En pratique, cela signifie que le modèle total fournit une estimation cohérente du *coût moyen attendu*, mais qu'il ne reconstruit pas parfaitement la distribution individuelle des montants. Cette limite n'est pas surprenante compte tenu de la rareté des atypiques et du cumul des erreurs de modélisation.

3.1.2.2 Assuré de référence

Pour conserver un lien direct avec la partie GLM, un profil d'assuré de référence a été défini à partir des mêmes grandes classes tarifaires. L'objectif n'est pas de prétendre fournir une vérité absolue sur un individu, mais d'obtenir un ordre de grandeur lisible et comparable entre approches.

TABLE 3.2 – Assuré de référence et coût moyen prédit

Variable	Modalité retenue
DriverAge_cls	<i>Conducteurs expérimentés [35-45]</i>
CarAge_cls	<i>Véhicule intermédiaire [5-10]</i>
Density_cls	<i>Zone peu dense</i>
Power_cls	<i>(d-e-f-g-k)</i>
Brand_cls	<i>French core</i>
Region_cls	<i>(C-B)</i>
Gas	<i>Diesel</i>
$\hat{p}_{atyp}$	<i>0.029139</i>
$\hat{C}_{attr}$	<i>1168.471436</i>
$\hat{C}_{atyp}^{hyb}$	<i>36617.980469</i>
$\hat{C}_{total}$	2201.440775

3.1.2.3 Recommandation pratique

Au vu des résultats obtenus, il apparaît plus raisonnable de **ne pas intégrer directement** la composante atypique dans le coût total comme une espérance pleine. Deux pistes plus prudentes peuvent être retenues :

- conserver la composante attritionnelle comme base principale du coût, puis ajouter les atypiques sous forme de **surprime** ou de **charge séparée**, à l'image de ce qui a été fait dans la partie GLM ;
- utiliser un **facteur de crédibilité** appliqué à la composante atypique, afin de ne pas faire porter au tarif la totalité d'une charge extrême encore trop incertaine.

Cette recommandation est importante du point de vue concurrentiel : un tarif intégrant trop fortement les atypiques risque de devenir non compétitif, même s'il est théoriquement cohérent d'un point de vue probabiliste.

3.2 Tableau comparatif GLM VS ML

TABLE 3.3 – Comparaison des approches GLM et machine learning pour la tarification

Élément comparé	Approche GLM	Approche machine learning
Seuil de séparation attritionnel / atypique	Quantile empirique à 97,5 %	Seuil fixé à 6 500, à partir d'une analyse empirique de la distribution et de méthodes d'isolement de valeurs atypiques
Traitement des sinistres atypiques	Traitement sous forme de surprime finale	Traitement spécifique par modélisation des valeurs extrêmes, puis intégration prudente dans le coût
Logique de modélisation du coût	Approche plus simple, directement exploitable et facilement interprétable	Approche plus fine, fondée sur la séparation attritionnel / atypique et sur plusieurs niveaux de modèles
Fréquence prédite pour l'assuré de référence	14,18 %	16,45 %
Coût attritionnel moyen prédit pour l'assuré de référence	1 219,88	1 168,47
Prime pure de l'assuré de référence	209,97	362,14
Lecture pratique	Tarif plus lisible, plus prudent dans sa structure et plus proche d'une logique de marché	Tarif plus sensible à la prise en compte du risque atypique, donc potentiellement moins compétitif sans ajustement complémentaire

3.3 Limites et perspectives

3.3.1 Limites pratiques et concurrentielles des approches retenues

La principale limite observée concerne la **prise en compte des sinistres atypiques**. Si l'on intègre directement leur coût estimé dans l'espérance totale sous la forme

$$\hat{C}_{\text{total}} = (1 - \hat{p}_{\text{atyp}})\hat{C}_{\text{attr}} + \hat{p}_{\text{atyp}}\hat{C}_{\text{atyp}},$$

on obtient rapidement des coûts moyens élevés, car une probabilité atypique faible mais non nulle reste multipliée par un coût atypique conditionnel très important. Cette construction est théoriquement cohérente, mais elle peut conduire en pratique à un tarif peu compétitif, surtout dans un marché d'assurance automobile fortement concurrentiel.

Autrement dit, une modélisation trop directe du risque atypique tend à surcharger le coût final, alors même que cette composante reste très instable, peu volumineuse et difficile à prédire finement. Le danger n'est donc pas uniquement statistique ; il est aussi **commercial et tarifaire**. Un tarif trop prudent sur les gros sinistres peut devenir économiquement défavorable s'il n'est pas soutenable face aux pratiques du marché.

La deuxième limite est celle de l'**interprétabilité**. Les modèles de boosting, les combinaisons hybrides et les mécanismes de crédibilité sont intéressants sur le plan technique, mais ils sont plus difficiles à expliquer qu'un GLM. Or, dans une logique actuarielle appliquée, un tarif doit pouvoir être compris, justifié et piloté. À ce titre, les GLM conservent un avantage fort : ils sont plus simples, plus lisibles, plus stables dans leur interprétation, et plus faciles à articuler avec une logique de marché.

Enfin, la qualité des résultats obtenus rappelle une limite fondamentale : **un modèle, même sophistiqué, ne peut extraire que l'information réellement contenue dans les données**. Dans notre cas, les méthodes de machine learning ont permis d'explorer davantage la structure du risque, mais elles n'ont pas transformé radicalement la qualité prédictive de la composante coût, précisément parce que les variables disponibles restent trop limitées.

3.3.2 Approche à privilégier en pratique

Au regard des résultats obtenus, l'approche la plus raisonnable d'un point de vue pratique n'est pas de retenir une intégration pleine et entière du coût atypique dans la composante coût moyenne. Une telle option est trop sensible à l'instabilité des extrêmes et risque de produire un tarif peu compétitif.

En pratique, deux approches paraissent plus pertinentes :

- **conserver la composante attritionnelle comme base principale du coût**, car elle est plus stable, plus fréquente et plus directement exploitable ;
- **traiter la composante atypique comme une surcharge séparée**, ou comme une charge complémentaire pondérée par un facteur de crédibilité.

Cette logique est plus proche de la pratique actuarielle observée dans la méthode GLM du projet. Elle présente plusieurs avantages : elle évite de faire peser intégralement la volatilité des atypiques sur le tarif, elle garde une structure lisible, et elle permet d'introduire une prudence sur le risque extrême sans surcharger excessivement la prime.

Une formulation du type

$$C_{\text{final}} = C_{\text{attr}} + \lambda \hat{p}_{\text{atyp}} \hat{C}_{\text{atyp}}, \quad \lambda \in [0, 1]$$

apparaît ainsi plus réaliste qu'une intégration complète de l'espérance atypique. Le facteur λ joue ici un rôle de crédibilité : il permet de conserver l'information fournie par les modèles sur les atypiques, tout en reconnaissant explicitement le caractère fragile et peu stable de cette composante.

Dans l'état actuel des données, une approche de ce type semble plus adaptée qu'une modélisation intégrale du coût total par espérance brute. En d'autres termes, les modèles avancés apportent une information utile, mais cette information doit être **encadrée** et **calibrée** avant d'être utilisée dans un tarif.

3.3.3 Ce qu'il faudrait pour aller vers des méthodes plus poussées

Les résultats obtenus ne doivent pas être interprétés comme une limite intrinsèque du machine learning, mais plutôt comme une conséquence du **manque d'information contenue dans la base**. Plusieurs variables cruciales, absentes des données disponibles, auraient probablement permis d'améliorer sensiblement la modélisation des coûts.

De façon synthétique, trois variables apparaissent particulièrement importantes :

- **le CRM / bonus-malus** : il synthétise une partie essentielle de l'historique de conduite et de sinistralité. Son absence est pénalisante, car il s'agit d'un indicateur central du niveau de risque ;
- **le kilométrage annuel parcouru** : il permet de mieux approcher l'exposition réelle au risque. Deux assurés de même profil ne présentent pas le même risque s'ils roulent très peu ou beaucoup ;
- **l'usage précis du véhicule** : usage privé, domicile-travail, usage professionnel ou intensif n'impliquent ni la même fréquence ni la même gravité des sinistres.

Dans une optique plus orientée coût, d'autres variables seraient également très précieuses, comme la **valeur du véhicule**, la **nature des dommages**, le **type de garantie mobilisée**, la **responsabilité**, ou encore des informations plus fines sur le **contexte du sinistre**. Ces variables permettraient de relier davantage la modélisation à la réalité économique du dommage, ce qui est indispensable pour affiner la sévérité.

Ainsi, pour pouvoir exploiter pleinement des méthodes plus poussées, il faudrait non seulement davantage de données, mais surtout des données **plus informatives du point de vue du risque**. Sans cet enrichissement, les approches avancées restent limitées dans leur capacité à améliorer significativement le tarif.

Conclusion

En synthèse, ce travail montre que les approches avancées permettent d'aller plus loin dans la compréhension des composantes coût et fréquence, notamment sur la distinction entre attritionnels et atypiques, sur l'analyse de la queue extrême, et sur l'exploration de modèles flexibles. Elles constituent donc un apport utile sur le plan méthodologique.

Néanmoins, dans un cadre actuariel appliqué et concurrentiel, la solution la plus pertinente demeure aujourd'hui une approche **prudente, lisible et calibrable**. Les GLM conservent à ce titre un avantage important : ils sont plus simples à interpréter, plus faciles à expliquer, et mieux adaptés à une logique de tarif de marché. Les méthodes de machine learning doivent ici être vues comme des outils complémentaires d'exploration, d'aide à la segmentation et d'analyse du risque extrême, plutôt que comme des substituts immédiats aux approches actuarielles usuelles.

La recommandation pratique issue de cette étude est donc la suivante :

- retenir une base de coût principalement portée par la composante attritionnelle ;
- traiter la composante atypique sous forme de surcharge ou de charge crédibilisée ;
- réserver l'usage des méthodes plus poussées à une logique d'enrichissement progressif, en attendant de disposer de données plus complètes et plus directement informatives sur le risque.

Cette position apparaît comme le meilleur compromis entre rigueur statistique, prudence actuarielle, interprétabilité du tarif et compétitivité sur le marché.

Références bibliographiques

[https ://www.trustauto.com/blog/diesel-vs-gasoline](https://www.trustauto.com/blog/diesel-vs-gasoline)